# 第 2 课课后作业使用说明

朱晨的 AI 智能体课 · Claude Code 经济学研究实战

对应材料：lab2_starter.zip　预计用时：约 2 小时　不需要提交

## 一、这份作业要做什么

从一个空文件夹开始，让智能体帮你走完一条完整的实证流程：拿到数据，写数据画像，清理，出图，做两个检查，最后写一份别人能照着重跑的 README。数据有两种选择：世界银行的公开数据，或者你自己从小红书、知乎采集的评论。

和第 1 课相比，这次的重点是整条流程：每一步都要落成脚本和记录，删掉对话以后流程照样能跑。

## 二、开始之前

| 需要什么 | 说明 |
| --- | --- |
| 第 1 课的环境 | Claude Code 能启动，Python 能在命令行调用。 |
| Git | 终端运行 git --version 能看到版本号。 |
| Node.js 20 或更新 | 只有标准档和进阶档需要，用来安装 Playwright MCP。终端运行 node --version 检查。 |
| Chrome 和手机 | 只有标准档和进阶档需要。登录时用小红书或知乎 App 扫码。 |
| lab2_starter.zip | 从课程主页下载。 |

## 三、第一步：解压参考资料，建一个空的项目文件夹

这一课把参考资料和项目分开放：starter pack 解压到 ~/lab2_starter，只当参考；真正干活的项目文件夹 ~/lab2 从空的开始。这样智能体打开项目时，看到的只有这个项目本身。

### macOS

```
cd ~
unzip ~/Downloads/lab2_starter.zip
```

### Windows（WSL2）

```
cd ~
unzip /mnt/c/Users/<你的 Windows 用户名>/Downloads/lab2_starter.zip
```

### 建项目文件夹（两种系统相同）

```
mkdir ~/lab2 && cd ~/lab2 && git init
cp ~/lab2_starter/CLAUDE.md.template CLAUDE.md
cp ~/lab2_starter/gitignore.txt .gitignore
```

用文本编辑器打开 `~/lab2/CLAUDE.md`，把研究问题、数据来源、软件版本改成你自己的。

**为什么要 .gitignore**　它让 Git 忽略原始数据和浏览器登录文件，这些东西就不会被误传到 GitHub。CLAUDE.md 里的规则是写给智能体的请求，.gitignore 才是真正挡住文件的那一道。

### 参考资料里有什么

| 文件 | 用途 |
|---|---|
| `opening_prompt_template.md` | 六个部分的开场提示模板，社媒版和世界银行版各一份 |
| `clarify_prompts.md` | 澄清问题用的三套提示：深度、广度、高度 |
| `collection_rules.md` | 社媒采集规则，复制进 CLAUDE.md |
| `setup_browser.md` | 安装浏览器工具的步骤 |
| `DATA_PROFILE_template.md` | 数据画像模板 |
| `COLLECTION_LOG_template.md` | 采集记录模板 |
| `README_template.md` | 项目 README 模板，含两个检查 |
| `clean_comments_example.py` | 参考清理脚本。先让智能体自己写，再拿来对照 |
| `download_wdi_structural.py` | 基础档参考下载脚本，同样用于对照 |
| `lab2_verify_checklist.md` | 验收清单 |
| `exit_ticket.md` | 课后 exit ticket |

## 四、第二步：选一档

| 档次 | 任务 | 登录平台 |
|---|---|---|
| 基础 | 世界银行数据：中国的农业就业占比和人均 GDP，画结构转型图 | 不需要 |
| 标准 | 自选一个和经济学相关的关键词，在小红书或知乎采 200–500 条评论，清理后画描述性图 | 需要 |
| 进阶 | 在标准档上比较两个关键词或两段时间，加一个简单的文本分类 | 需要 |

三档要求一样，选你想练的那一档就行。基础档可以跳过第六步。

## 五、第三步：先把问题想清楚

在 `~/lab2` 里启动 `claude`，用几句话告诉它你关心什么、打算用什么数据。然后把 `clarify_prompts.md` 里的“增加研究深度”提示粘贴进去。

它会先带你判断问题的层次、你有哪些没验证的假设、最后用什么方式验证。这一步不急着出结果，十分钟左右即可。聊完以后，你应该能回答：来源是什么、一行数据是什么、测什么、怎么汇总、输出什么。

## 六、第四步：装好浏览器工具（标准档、进阶档）

1. 在 `~/lab2` 里（先退出 Claude Code）运行下面的命令，安装 Playwright MCP：

```
claude mcp add playwright -- npx @playwright/mcp@latest
```

2. 启动 `claude`，输入 `/mcp`，看到 playwright 处于已连接状态即可。
3. 把 `collection_rules.md` 里的规则复制进 CLAUDE.md，然后退出、重启 Claude Code，让新规则生效。

**想用自己的 Chrome**　也可以用 Claude in Chrome 扩展代替 Playwright MCP，步骤见 `setup_browser.md`。

## 七、第五步：写开场提示，开始干活

1. 打开 `opening_prompt_template.md`，选对应的版本，把【】里的内容改成你的。最后一部分“留痕”一字不删。
2. 把改好的提示原文存进 `~/lab2/prompts_used.md`。
3. 在 Claude Code 里按 Shift+Tab 切到 Plan mode，粘贴提示。读完它的计划再决定执行。

### 采集时会发生什么（标准档、进阶档）

1. 一个新的浏览器窗口会打开，停在小红书或知乎的登录页。
2. 用手机 App 扫码登录。登录成功后，回到终端告诉它“已登录，继续”。
3. 它会搜索关键词、切换排序、逐篇打开笔记读评论。你会看到它每一步在做什么。
4. 如果它发现采到的条数比页面显示的少，通常会自己改成滚动加载。你看着就行。
5. 采完以后，它把原始数据存到 `data/raw/`，并写好 `COLLECTION_LOG.md`。

**遇到验证码**　停下来。可以自己在浏览器里完成验证后让它继续，也可以结束这次采集。不要让它尝试绕过。

## 八、第六步：清理、出图、检查

1. 先读 `DATA_PROFILE.md`。看一行是什么、唯一性检验的两个数字是否一致、缺失比例、每篇实际条数和页面显示的条数。这里发现的问题，比图出来以后再发现便宜得多。
2. 让它先画原始序列：每篇笔记的评论数、每天的评论数（基础档画逐年原始值）。

3. 看图之前，把两个检查写进 README。可以参考 **README_template.md**。例如：随机抽 10 条评论回网页逐条找到；评论时间不早于笔记发布时间。
4. 让它出图。不满意就改，每轮只改一两处，最多三轮。
5. 做那两个检查，把结果写进 README。
6. 最后让它补全 README：怎样从原始文件重跑到最终的图。

### 在新文件夹里重跑一遍

这一步检验 README 是否真的够用。原始数据没有进 Git，所以要单独复制过去：

```
git -C ~/lab2 add -A && git -C ~/lab2 commit -m "lab2"
git clone ~/lab2 ~/lab2_rerun
mkdir -p ~/lab2_rerun/data && cp -r ~/lab2/data/raw ~/lab2_rerun/data/
cd ~/lab2_rerun
```

然后只按 README 里写的命令操作，看能不能得到同一张图。

## 九、第七步：自查与 exit ticket

打开 **~/lab2_starter/lab2_verify_checklist.md** 逐项检查。全部通过后，填写 **exit_ticket.md**。

做完以后，你的项目文件夹大致是这样：

```
lab2/
├── CLAUDE.md
├── prompts_used.md
├── COLLECTION_LOG.md
├── DATA_PROFILE.md
├── DECISIONS.md
├── LOG.md
├── README.md
├── data/raw/
├── data/processed/
├── scripts/
└── output/
```

基础档没有 COLLECTION_LOG.md。data/raw/ 在你的电脑上，但不在 Git 里。

## 十、常见问题

| 遇到的情况 | 怎么办 |
| --- | --- |
| **/mcp** 里没有 playwright | 确认是在 **~/lab2** 里运行的安装命令，并且 Node.js 是 20 或更新版本。改完后重启 Claude Code。 |
| 浏览器窗口没有出现 | 在提示里明确写“用 playwright mcp 打开浏览器”。第一次运行要下载浏览器，等一两分钟。 |

| 遇到的情况 | 怎么办 |
| --- | --- |
| 扫码以后它没有反应 | 回到终端，告诉它“已登录，继续”。 |
| 采到的条数比页面显示的少 | 让它滚动到不再出现新评论再读取，并在 COLLECTION_LOG.md 里记录前后条数。 |
| 很多评论的时间解析失败 | 看看 DATA_PROFILE.md 里列出的时间格式，让它补上缺的格式。对照参考脚本 clean_comments_example.py 里的处理方式。 |
| **`git check-ignore data/raw/`** 没有输出 | 检查是否运行过 **`git init`**，以及 gitignore.txt 是否已改名为 **`.gitignore`**。 |
| git commit 提示要设置身份 | 第一次用 Git 时运行 **`git config --global user.name "`**你的名字**"** 和 **`git config --global user.email "`**你的邮箱**"**，再重新提交。 |
| 世界银行 API 连不上 | 在浏览器里打开世界银行 WDI 网站，手动下载两个指标的 CSV，放进 data/raw/，在 DECISIONS.md 里写明。 |
| 它越做越偏 | 按 Esc 停下，用一句话说清要改什么。偏得太远就开新会话，让它先读 LOG.md。 |

## 十一、做完以后

- **确认数据。**第 3 课要用 CHNS 或 CHARLS。课程不分发数据，请确认已经自行申请并下载到本地。还没拿到的，第 3 课先用公开数据。
- **保管好原始数据。**社媒原始数据只留在你自己的电脑上，不上传、不分享。