朱晨的 AI 智能体课

Claude Code 经济学研究实战

第 3 课　微观调查数据：审查、清理、合并

朱晨　中国农业大学经济管理学院
公众号：遗传社科研究　GitHub： maxwell2732

遗传社科研究

今天的安排

- **0:00–0:50　讲义**　数据规矩、请求与强制、审查、调查数据的坑、合并
- **0:50–1:35　演示**　用 research harness 清理 CHNS
- **1:35–2:00　作业说明和 exit ticket**
- **课后约 2 小时**　审查、清理、合并你自己的调查数据

还没拿到数据的同学，先用世界银行数据把流程走一遍。

这一课的数据不一样

	第 1、2 课	第 3 课起
数据	世界银行、社媒评论	CHNS、CHARLS 等调查数据
怎么得到	公开下载或自己采集	签协议、申请、审核
能不能分享	公开数据可以	不能再分发
谁负责	你	你，按协议负责

授权数据的规矩

- 不得再分发：不发给同学，不放进作业包，不上传网盘
- 不得上传到公开仓库：原始数据和清理后的个体数据都不进 Git
- 只用于申请时写明的研究用途
- 原始数据只读：清理只能生成新文件，不能改原文件
- 产出里不出现能识别个人的信息

常见错误 为了让同学复现，把数据打包推到 GitHub。复现靠的是脚本和说明，数据让对方自己申请。

智能体读到的内容会发给模型

可以让它读

- 变量名和变量标签
- codebook 、问卷说明
- 汇总统计：行数、缺失比例、取值范围
- 脚本运行后的报告

尽量不要

- 大段原始记录打印进对话
- 带姓名、住址、电话的字段
- 整份数据文件贴进提示

我的做法

它写脚本，脚本在本地读数据，对话里只出现汇总结果。查一下数据协议对第三方处理有没有规定。

写在 CLAUDE.md 里的只是请求

`CLAUDE.md`、`skill`	每次会话读入的规则	请求
`.gitignore`	让 Git 忽略原始数据	强制
`deny` 规则	settings.json 里禁止它编辑 data/raw/	强制
`hook`	你写的脚本，动手前检查，可以拦下	强制

```
"permissions": {
  "deny": [
    "Edit(./data/raw/**)"
  ]
}
```

Edit 规则覆盖所有编辑类工具；
写成 Write(...) 不会生效。
deny 挡不住它写的 Python 脚本。

原始数据有没有被改过：用哈希值说话

开始前	→	清理	→	结束后
python hash_raw.py save 存下每个文件的 SHA-256		脚本只读原始数据， 输出写到 data/processed/		python hash_raw.py check 逐个对比，报告是否一致

```
[check] data/raw/w2011/demographic_background.dta    一致
[check] data/raw/w2013/Demographic_Background.dta    一致
[check] 共 24 个文件，全部一致
```

示意（文件名和数量为示例）

“原始数据没被改过”从一句保证，变成一个可以检查的事实。

Research harness 的前三步



- **`/research-harness-setup`** study_spec.md 、文件夹结构、 data/raw/READONLY.md
- **`/research-harness-audit`** reports/data_audit_report.md ，不改任何数据
- **`/research-harness-clean`** 清理脚本、清理报告、合并报告、 data/processed/

前一步没做完，后一步的 skill 会停下来，告诉你缺什么。

先审查，再清理

1. 文件清单：大小、格式、行数、列数
2. 变量清单：类型、缺失、取值范围
3. ID：哪个是 ID，在文件内是否唯一
4. 时间：范围、格式、各轮是否连续
5. 缺失：哪些变量缺失超过一半
6. 重复：完全重复行、ID 重复
7. 单位与编码：元还是千元，-9、99、9999
8. 合并键：哪些文件能合并，重叠比例
9. 可行性：规格里要的变量能不能构造

审查只读不改，最后出一份 data_audit_report.md 。

动手之前，先问可行性

> “我想要一个 CHARLS 2011、2013、2015、2018 年的个人 - 年份面板，包含出生年、性别、教育、婚姻、是否有医保。动手之前，先告诉我要做哪些事、可能缺什么、哪些地方你没有把握。先不要写代码。”

一个好的回答应该提到

- 各轮的文件名、变量名不一致
- ID 格式各轮不同，跨轮匹配要核对
- 有些变量只在部分轮次有，或者只记录了更新
- 需要你决定的样本筛选条件

调查面板数据里的坑

问题	CHARLS 中的例子	处理
文件名	2011 全小写； 2013 起首字母大写； 2018 部分模块改名	按轮次写明文件名映射，不要写死
变量名	出生年： 2011 BA002_1 ， 2013 ZBA002_1 ， 2018 BA004_W3_1	先读元数据找变量，再写清理脚本
ID 格式	2011 为 11 位， 2013 起为 12 位	跨轮匹配前先核对，必要时用官方对照
预填变量	2013 年部分变量只记录更新，预填值在 Z 开头的变量里	两者合并使用，写进 DECISIONS.md
缺失与单位	-9 、 99 、 9999 等特殊码；元与千元	审查时列出，清理时统一

以 CHARLS 公开版为例，具体以你使用的数据版本和官方文档为准。

变量名对上了，含义还要回到问卷

教育 BD001

4 = 小学毕业
5 = 初中毕业

“初中及以上”应写 ⩾ 5，写成 ⩾ 4 会把小学毕业算进去

医保（多选题）

2011、**2013**：未选为空值
2018：未选为 **0**

同一个判断条件用在不同轮次，结果完全不同

验证一下

这类错误不会报错。对照问卷原文，或者对照原论文的描述统计表，才能发现。

“跑通了”不等于“对了”

“脚本没报错。”	只说明代码语法没问题，不说明筛选、合并是对的
“样本量看着差不多。”	“差不多”不是和一个事先写下的预期数字比较
“这份数据我以前用过。”	以前的经验验证不了这一次的变量、轮次和筛选
“合并成功了。”	**最危险的一句。执行成功和结果正确是两件事**

每一次合并都要有报告

```
[merge] 个人表 + 家户表   键 = (householdID, wave)   关系 = 多对一
        左表 n = 52,140     右表 n = 23,880
        合并后 n = 52,140 (行数不变，符合多对一)
        匹配 51,902 (99.5%)   只在左边 238   只在右边 1,105
        预期匹配率 ≥ 99%      结果：通过
```

示意（数字为示例）

- 左表、右表、合并后的行数；匹配、只在左、只在右
- 写明关系（一对一、多对一），用 **validate="m:1"** 让代码检查
- 匹配率和事先写下的预期比较；没匹配上的要看是谁

Codebook 是写给下一次会话的

variable_name	description	unit	source	cleaning_note
edu_middle	是否初中及以上（BD001 ⩾ 5）	0/1	w2011 BD001	阈值见 DECISIONS.md

- 定义从 Stata 变量标签读出来，覆盖率目标 99% 以上
- 清理时新造的变量，手写定义，写明来源和规则
- 不要手打：由脚本生成，和数据一起更新

验证一下

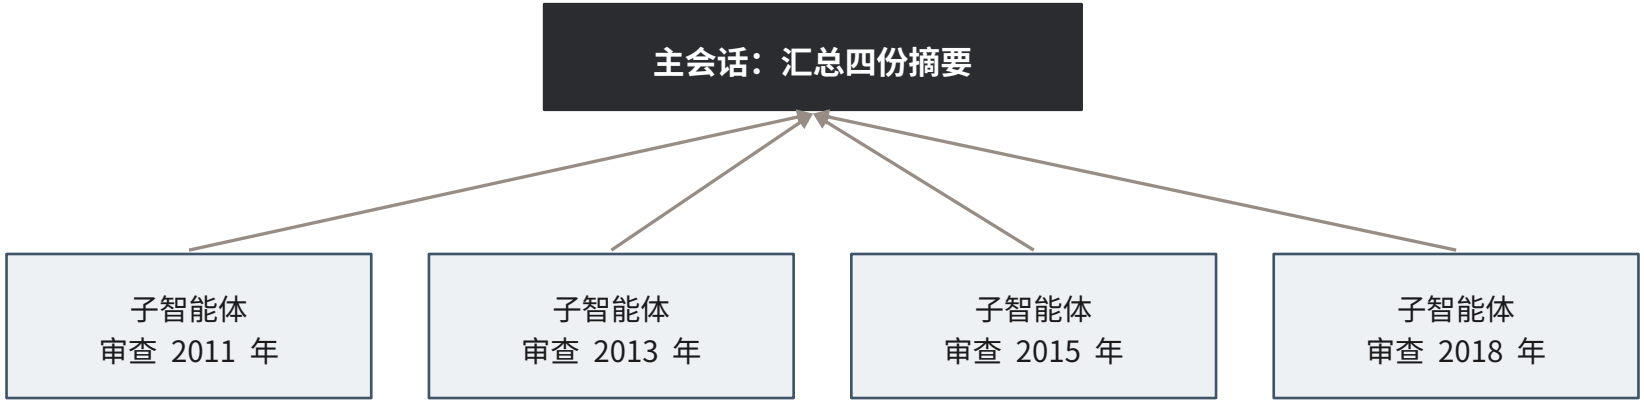
开一个新会话，只让它读 codebook，问它五个变量的含义。答对了才算合格。

数据很宽的时候

- 找变量只读元数据： `pyreadstat.read_dta(path, metadataonly=True)`
- 读数据只读需要的列： `usecols=[...]`
- 中间文件用 parquet ，读写快，保留类型
- 合并时只带键列做匹配检查，不复制整张宽表

这些做法写进 CLAUDE.md ，智能体就会照着做。我的 harness 仓库 CLAUDE.md 第 9 节有完整的规则。

把审查分给子智能体



每个子智能体有自己的上下文，只把摘要交回主会话。

提示里写：“每一轮数据分给一个子智能体审查，最后汇总成一份报告。”

第 3 课要记住的三件事

处理授权数据

1. 保护原始数据靠强制手段： .gitignore 、 deny 规则、哈希校验。
2. 先审查，再清理。审查报告读完再动手。
3. 合并成功和合并正确是两件事。每次合并都要有报告。

现场演示（0:50–1:35）

- 克隆 harness 仓库，数据放进 data/raw/，存一次哈希值
- **/research-harness-setup** 和 **/research-harness-audit**，读审查报告
- 审查报告指出：特殊缺失码被当成普通数值
- 写清理计划，**/research-harness-clean**，看合并报告
- 新会话只读 codebook，回答五个变量的含义
- 再核对一次哈希值，确认原始数据没被改过

你会看到的



示意图。变量名和数字为示例

它标记出来等你确认，没有自己去改。

课后作业（约 2 小时）

主路线	备选路线
自己申请的 CHNS 或 CHARLS 至少三轮合并成个人 - 年份面板 审查报告、清理报告、合并报告、 codebook	世界银行：三个指标文件 + 国家信息表 合并成国家 - 年份面板（含多对一合并） 拿到调查数据后补做主路线

两条路线相同的要求

- 开始前存哈希值，结束后核对一致
- deny 规则和 .gitignore 生效；数据不进 Git
- 每次合并都有报告； codebook 有变量定义，新会话能读懂
- 对照 **`lab3_verify_checklist.md`** 自查

Exit ticket 和下一课的准备

- **Exit ticket** 一个想明白的概念、一个出错的地方、下次相信结果前要核对什么
- **本课专属问题** 哪一个合并或变量编码最让你不放心？打算怎样核对？
- **下一课** 计量识别与论文复现，写出你的第一个 Skill 。会用到这次清理好的面板