第 3 课课后作业使用说明

朱晨的 AI 智能体课 · Claude Code 经济学研究实战

对应材料：lab3_starter.zip　预计用时：约 2 小时　不需要提交

一、这份作业要做什么

用 research harness 把你申请到的 CHNS 或 CHARLS 审查一遍，再清理、合并成一个个人-年份面板，同时得到审查报告、清理报告、合并报告和一份带变量定义的 codebook。

这一课的数据是授权数据，所以作业的一半是保护：原始数据只读，不进 Git，清理前后用哈希值核对没有被改过。还没拿到调查数据的同学，先用世界银行数据走一遍同样的流程。

二、开始之前

需要什么	说明
前两课的环境	Claude Code、Python、Git 都能在命令行使用。
Python 包	pandas、pyreadstat、pyarrow。终端运行：pip install pandas pyreadstat pyarrow
CHNS 或 CHARLS	你自己申请下载的数据，至少三轮。还没拿到的走备选路线。
lab3_starter.zip	从课程主页下载。

关于数据　课程不分发任何数据。CHNS、CHARLS 不得分享、不得上传到公开仓库。清理后的个体数据也一样。

三、第一步：解压参考资料，建项目文件夹

starter pack 解压到 **~/lab3_starter**，只当参考资料。项目文件夹用 research harness 仓库，克隆到 **~/lab3**：

Windows（WSL2）用户把第二行换成 **unzip /mnt/c/Users/**<你的 **Windows** 用户名>**/Downloads/lab3_starter.zip**。

```
cd ~
unzip ~/Downloads/lab3_starter.zip
git clone https://github.com/maxwell2732/claudecode-research-harness-workflow.git lab3
cd lab3
mkdir -p data/raw .claude
```

参考资料里有什么

文件	用途
`prompts.md`	本课用到的提示：可行性、审查、清理计划、清理、新会话检查
`data_rules_for_CLAUDE.md`	授权数据规则，追加到项目的 CLAUDE.md
`settings.json.template`	禁止智能体编辑原始数据的 deny 规则
`hash_raw.py`	原始数据哈希校验：清理前存，清理后核对
`codebook_from_dta.py`	参考脚本：从 Stata 变量标签生成变量清单和 codebook
`checked_merge.py`	参考函数：带报告的合并，自动检查合并关系
`download_wdi_modules.py`	备选路线：下载世界银行的几个文件
`lab3_verify_checklist.md`	验收清单
`exit_ticket.md`	课后 exit ticket

四、第二步：放数据，加保护

放数据

主路线：把调查数据复制进 `~/lab3/data/raw/`，每一轮建一个子文件夹，例如 `data/raw/w2011/`、`data/raw/w2013/`。

备选路线：在 ~/lab3 里运行

```
python ~/lab3_starter/download_wdi_modules.py
```

加三道保护

1. **deny 规则：**禁止智能体用编辑工具改 data/raw/。

```
cp ~/lab3_starter/settings.json.template .claude/settings.json
```

2. **数据规则写进 CLAUDE.md：**追加到末尾。

```
cat ~/lab3_starter/data_rules_for_CLAUDE.md >> CLAUDE.md
```

3. **存哈希值：**记下每个原始文件的 SHA-256。

```
python ~/lab3_starter/hash_raw.py save
```

再确认 Git 会忽略原始数据。下面这条命令应该输出 data/raw：

```
git check-ignore data/raw
```

最后启动 `claude`，输入 `/permissions`，确认 deny 列表里有 `Edit(./data/raw/**)`。

为什么要三道　CLAUDE.md 里的规则是请求，智能体通常会遵守，但不能保证。deny 规则能挡住它的编辑工具，但挡不住它写的 Python 脚本。哈希校验不挡任何东西，但能在最后证明原始数据没被改过。

五、第三步：先问可行性，再审查

1. 把 **prompts.md** 第 1 条“可行性”提示改成你的面板需求，粘贴进去。它会告诉你要做哪些事、可能缺什么。读完，把要点存进 DECISIONS.md。
2. 运行 **/research-harness-setup**，按提示写一句研究问题。它会生成 study_spec.md 和文件夹结构。
3. 运行 **/research-harness-audit --all**。轮次多的话，可以让每一轮分给一个子智能体（见 prompts.md 第 3 条）。
4. 打开 **reports/data_audit_report.md** 读一遍。重点看：ID 是否唯一、各轮变量名的差异、特殊缺失码（-9、99、9999 之类）、可能的合并键。

审查阶段它不会改数据　如果它发现可疑的编码，会标记出来等你确认。含义不确定的，回到问卷或数据官方文档核对。

六、第四步：写清理计划，清理与合并

1. 用 **prompts.md** 第 4 条，让它根据审查报告起草清理计划，先不执行。
2. 逐条核对清理计划：变量的跨轮映射、编码含义（对照问卷）、新造变量的定义、每次合并的键和关系（一对一还是多对一）、预期匹配率。改好再往下。
3. 用 **prompts.md** 第 5 条运行 **/research-harness-clean**。
4. 看合并报告：每次合并的行数变化、匹配率、没匹配上的是谁。匹配率低于预期，要找到原因，写进清理报告。

一份合格的合并报告大致是这样（数字为示例）：

```
[merge] 个人表 + 家户表    键 = ('householdID', 'wave')    关系 = m:1
        左表 n = 52,140     右表 n = 23,880
        合并后 n = 52,140
        匹配 51,902 (99.5%)    只在左边 238
        预期匹配率 ≥ 99%       结果：通过
```

想看看合并检查怎么写，运行 **python ~/lab3_starter/checked_merge.py**，里面有一个正常的例子和一个被拦下的例子。

七、第五步：检查 codebook 和原始数据

新会话检查 codebook

退出 Claude Code，重新启动一个新会话，用 **prompts.md** 第 6 条，只让它读 codebook，回答五个变量的含义。五个都答对才算合格。答错的，回去补 codebook 里的定义。

codebook 的定义覆盖率不够，可以对照参考脚本 **`codebook_from_dta.py`**：它从 Stata 变量标签里读定义，新造的变量写进 extra_labels.csv。

核对哈希值

```
python ~/lab3_starter/hash_raw.py check
```

最后一行显示“全部一致”，说明原始数据从头到尾没被改过。

八、第六步：自查与 exit ticket

打开 **`~/lab3_starter/lab3_verify_checklist.md`** 逐项检查，全部通过后填写 **`exit_ticket.md`**。清理好的面板留在本地，第 4 课还要用。

做完以后，项目里新增的内容大致是这样：

```
lab3/
├── .claude/settings.json
├── CLAUDE.md
├── DECISIONS.md
├── raw_hashes.txt
├── study_spec.md
├── data/raw/
├── data/processed/
├── reports/
└── scripts/
```

data/raw/ 和 data/processed/ 都不进 Git；reports/ 里是审查报告、清理计划、清理报告和合并报告；raw_hashes.txt 只有文件名和哈希值，可以提交。

九、常见问题

遇到的情况	怎么办
`/permissions` 里看不到 deny 规则	确认文件在 **`~/lab3/.claude/settings.json`**，并且是从 ~/lab3 启动的 Claude Code。改完要重启。
启动时提示某条规则不会生效	文件路径的限制要写成 **`Edit(...)`**，写成 Write(...) 不会生效。
`git check-ignore data/raw` 没有输出	确认是在 ~/lab3 里运行的。harness 仓库的 .gitignore 已经包含 data/raw/。
hash_raw.py check 显示有文件被修改	先别继续。用 git 和日志找出是哪一步改的，从备份重新放一份原始数据，重新 save。
读 .dta 很慢或者内存不够	找变量时只读元数据（metadataonly=True），读数据时只读需要的列，中间文件存成 parquet。
skill 提示缺少前一步的文件	按顺序做：setup → audit → 清理计划 → clean。它停下来是在提醒你跳过了检查。

遇到的情况	怎么办
跨轮按 ID 匹配大量失败	各轮 ID 的长度或格式可能不同。先在审查报告里核对，必要时使用数据官方提供的 ID 对照表。
备选路线下载失败	Codex 用户先在 config.toml 打开联网；仍然不行，可以在浏览器里从世界银行网站手动下载 CSV。