朱晨的 AI 智能体课

Claude Code 经济学研究实战

第 4 课　计量识别与论文复现，写出第一个 Skill

朱晨　中国农业大学经济管理学院
公众号：遗传社科研究　GitHub： maxwell2732

遗传社科研究

今天的安排

- **0:00–0:50　讲义**　识别、处理时间、 staggered DID 、复现协议、写 skill
- **0:50–1:35　演示**　长护险 DID 、美貌经济学复现、起草 SKILL.md
- **1:35–2:00　作业说明和 exit ticket**
- **课后约 2 小时**　DID 或复现二选一，并写出你的第一个 skill

没有 CHNS 或 CHARLS 的同学，可以用自己手头的数据，配一篇匹配的文献来练。

第一部分

识别与 DID

处理时间从哪里来， staggered DID ，事件研究图怎么看，结果不理想时怎么办。案例：CHARLS 与长期护理保险试点。

智能体能写 csdid，识别要靠人判断

它做得快

- 写估计代码： csdid 、事件研究
- 整理回归表，输出 tex 和 csv
- 画事件研究图
- 跑稳健性检验

要你来判断

- 处理时间对不对，出处是什么
- 对照组合不合适
- 处理前趋势能不能接受
- 结果能不能写成因果结论

这一课的 DID 案例：代码全对，识别有问题。

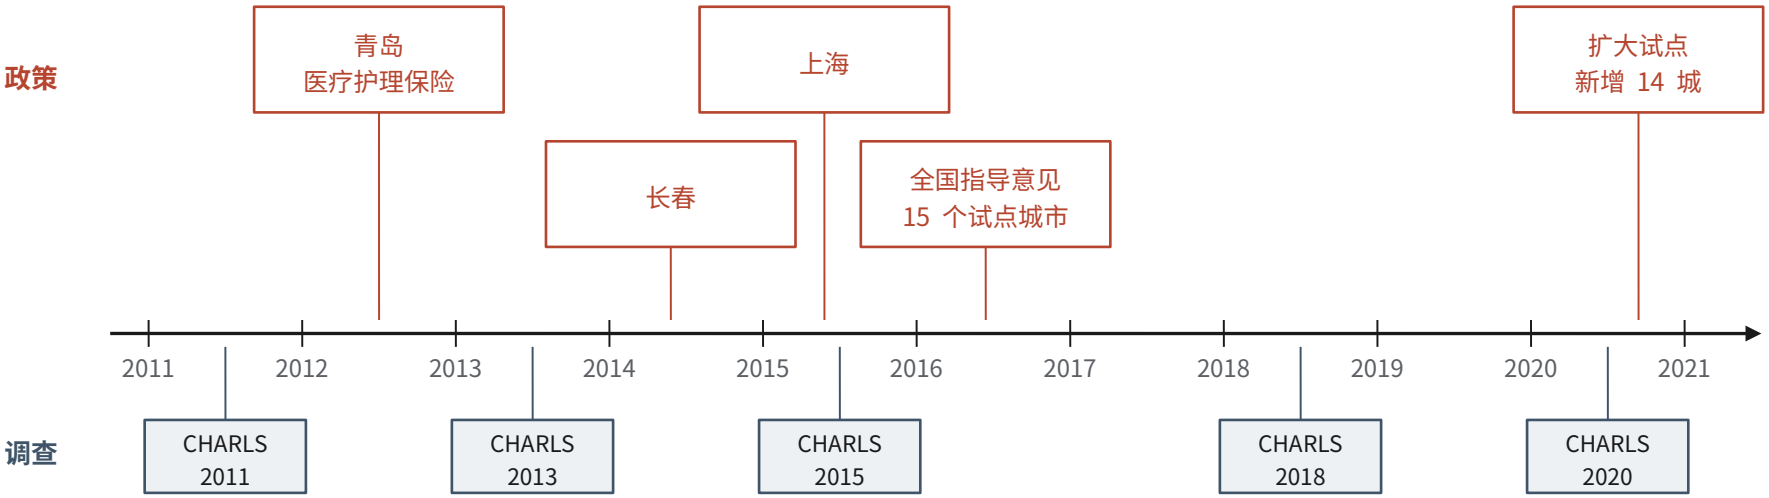
DID 动手之前，先问可行性

> “我想用 CHARLS 评估长期护理保险试点对【就业、收入、睡眠时长】的影响。数据在 `data/processed/panel.parquet`。动手之前，先告诉我：处理组和对照组怎么定义，处理时间从哪里来、怎样核对，哪几轮在处理前，有没有需要担心的同期政策。先不要写代码。”

一个好的回答应该提到

- 处理时间要逐个城市核对政策文件
- 事件研究需要足够的处理前轮次
- 对照组里有没有后来也被处理的单位
- 同一时期的其他政策可能混在一起

处理时间要有出处



调查轮次的位置为示意。政策时间来源：人社厅发〔2016〕80 号；各地政策文件与公开报道。具体以政策原文为准。

统一设成 2016 年，青岛、长春、上海的 2013 、 2015 年两轮就被当成了处理前。

把处理时间统一设成 2016 年，会出什么问题

1

处理前被污染

几个城市 2016 年前已有制度，处理前系数里混进了处理效应

2

不是真正的 staggered

统一一年开始只有一个批次；按实际起始年份编码才是 staggered

3

2020 年新增城市怎么办

扩大试点与 CHARLS 2020 调查时间接近，归到哪一组要人决定

验证一下

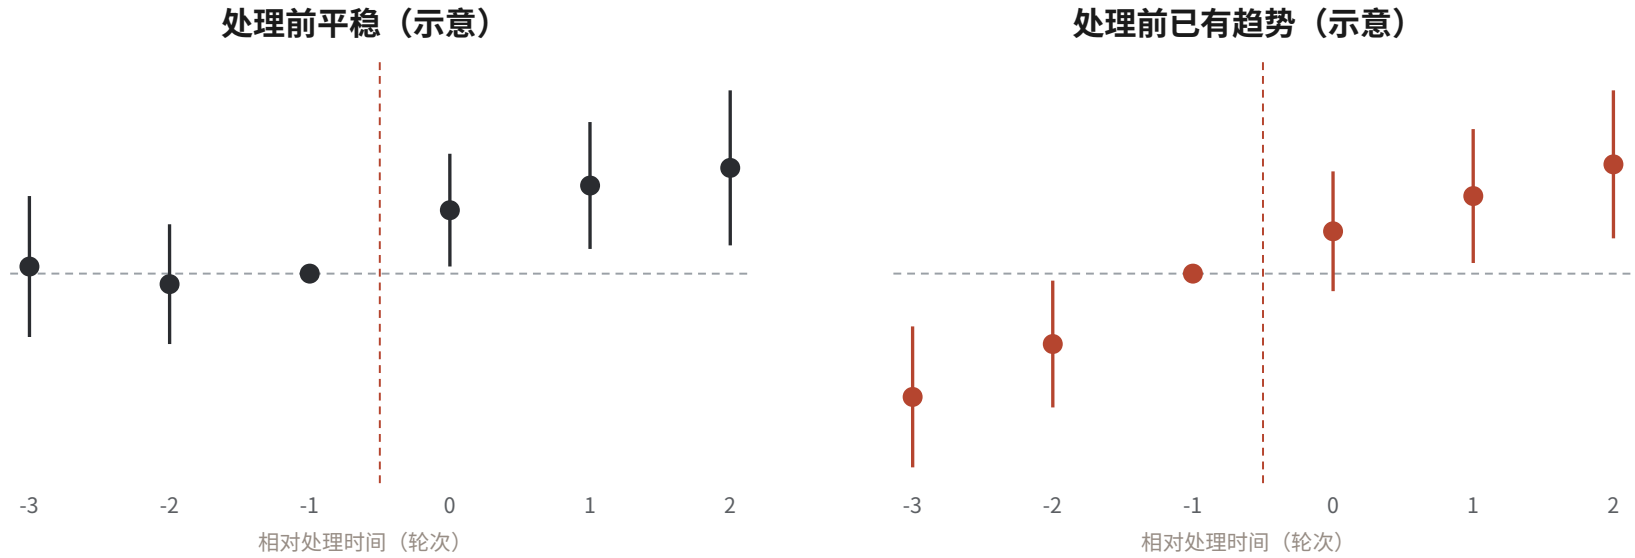
每个处理单位的起始时间，写进一张表，并注明政策文件出处。

Staggered DID 和传统 TWFE 的问题

- 处理时间不同、效应随时间变化时， TWFE 会拿已被处理的单位当对照，权重可能为负
- Goodman-Bacon （2021）的分解说明了问题出在哪里
- 选哪种估计量，取决于你的处理结构，写进 DECISIONS.md

估计量	Stata	R
Callaway & Sant'Anna （2021）	`csdid`	`did`
Sun & Abraham （2021）	`eventstudyinteract`	`fixest::sunab`
de Chaisemartin & D'Haultfœuille （2020）	`did_multiplegt`	`DIDmultiplegt`
Borusyak, Jaravel & Spiess （2024）	`did_imputation`	`didimputation`

事件研究图怎么看



示意图，非真实结果。 -1 期为基期。

常见错误　处理前系数不显著，就说平行趋势成立。不显著只是没发现明显的反例。

结果不理想，结论就是不能用

常见错误

让智能体一轮一轮换设定，直到某个系数显著为止。它换设定几乎没有成本，这让反复试设定变得比以前容易得多。

- 主设定和稳健性检验，事先写进分析计划
- 计划外的每一次尝试，都记进 DECISIONS.md
- 结果不稳健，报告里如实写；设计支持不了的结论不写

这个案例的结论：代码跑通了，识别设计支持不了因果结论。

让审稿子智能体先看一遍

`econometric-reviewer`	识别策略、模型设定、处理时间、对照组
`stata-reviewer`	代码可复现性、日志、命名、规范
`verifier`	表格和正文里的数字是否一致

它们在独立的上下文里工作，没参与写代码，更容易看出问题。

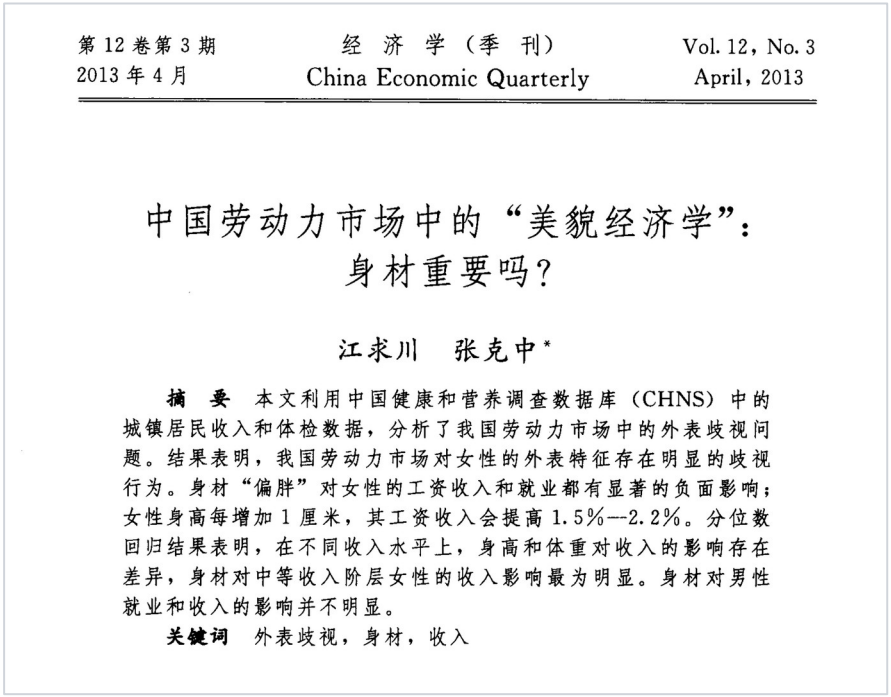
每条意见都要回应：接受，或者拒绝并说明理由，写下来。

第二部分

论文复现

换一个案例。复现协议，用固定格式读论文，事先定容差，把偏差说清楚。案例：江求川、张克中（2013）。

复现案例：中国劳动力市场中的“美貌经济学”



第 12 卷第 3 期　　经 济 学（季 刊）　　Vol. 12, No. 3
2013 年 4 月　　China Economic Quarterly　　April, 2013

中国劳动力市场中的“美貌经济学”：
身材重要吗？

江求川　张克中*

摘　要　本文利用中国健康和营养调查数据库（CHNS）中的城镇居民收入和体检数据，分析了我国劳动力市场中的外表歧视问题。结果表明，我国劳动力市场对女性的外表特征存在明显的歧视行为。身材“偏胖”对女性的工资收入和就业都有显著的负面影响；女性身高每增加 1 厘米，其工资收入会提高 1.5%—2.2%。分位数回归结果表明，在不同收入水平上，身高和体重对收入的影响存在差异，身材对中等收入阶层女性的收入影响最为明显。身材对男性就业和收入的影响并不明显。

关键词　外表歧视，身材，收入

论文

江求川、张克中（2013），《经济学（季刊）》第 12 卷第 3 期

数据

CHNS 城镇居民的收入和体检数据

主要结论

身材偏胖对女性的工资和就业有负面影响；女性身高每增加 1 厘米，工资提高 1.5% 到 2.2%；对男性影响不明显

复现工具

paper-replicate-agent-demo

复现协议

盘点	定目标	翻译	对比	解释
数据、样本、变量	系数、样本量、容差 跑代码之前写好	写成你的代码	逐项标 PASS / FAIL / NOTE	每个偏差写出原因

验证一下

容差在跑代码之前写进 replication_targets.md 。事后再定容差，等于看着结果画靶子。

用固定格式读论文

研究问题

一句话

制度背景

设计依赖的政策、市场或制度细节

样本

数据、年份、每步筛选后的 N，出现在哪张表

识别用的变异

什么变了，为什么和结果无关

主要结果

表号、列号、系数、标准误、经济含义

能否复现

数据能否获得，哪部分能重建

美貌经济学复现：主要结论复现上了

目标	原文	复现	判断
女性身高 β （表 2， M7）	0.019 (t=3.89)	0.016 (t=3.25)	**PASS**
女性超重 β （表 2， M7）	−0.154 (t=−2.30)	−0.119 (t=−1.89)	**边界**
女性样本量（表 2， M7）	523	471	**FAIL**
男性身高 β （表 3， M7）	−0.001 (t=−0.21)	0.000 (t=0.06)	**NOTE**
女性体重 probit β （表 6）	−0.011 (t=−2.38)	−0.011 (t=−1.81)	**PASS**

江求川、张克中（2013），《经济学（季刊）》；CHNS 2006。总体评价：PARTIAL，主要经济学结论复现了，细节有偏差。

偏差要说得清楚

- 服务业的界定用了近似口径
- BMI 分位点在各分析样本内分别计算
- “越胖越健康”的态度变量在数据里没找到，去掉了
- Model 7 包含哪些控制变量，靠比对系数反推
- 原文没写标准误类型，用了异方差稳健标准误

复现报告的标准

每个 FAIL 和 NOTE 都有原因，每个原因都能查到出处。

第三部分

写出第一个 Skill

把前两部分反复做的流程写下来，下次智能体遇到类似任务会自己调用。 SKILL.md 的结构、 description 怎么写、新会话测试。

你反复做的事，就是 SOP

提示

一次性的指令
“帮我画一张事件研究图”

Skill

封装好的一项能力或操作规范
did-checklist 、 replication-targets

Workflow

从头到尾的一整套流程
research harness 的七步

今天把这节课做过的流程，写成你的第一个 skill 。

SKILL.md 的结构

```
---
name: replication-targets
description: 当用户要复现一篇实证论文、
  或要把论文结果整理成复现目标时使用……
---
# 复现目标
## 步骤
1. 按六项格式读论文，写 paper_notes.md
2. 列出目标系数和样本量，写明表号列号
3. 为每个目标定容差，停下来请用户确认
## 产出
- quality_reports/<论文>_replication_targets.md
```

- **description**：什么时候用它，最重要的一句
- **步骤**：按顺序写，可以检查
- **停下来问人**：需要判断的地方写明
- **产出**：文件名和位置
- `.claude/skills/<名字>/SKILL.md`

最常见的错误： description 写成了标题

写成了标题

`description: DID 检查清单`

写成了触发条件

`description:` 当用户要评估一项政策的效果、做双重差分或事件研究时使用。先核对处理时间的出处。不用于横截面回归。

智能体靠 description 判断现在该不该用这个 skill 。写清什么情况下用，最好再写一句什么时候不用。

写一个 skill 的五步



> “把我们刚才做的流程写成 `.claude/skills/did-checklist/SKILL.md`。我纠正过你的地方写成规则；需要人判断的地方写成‘停下来问我’；`description` 写成什么情况下该用它，不要写成标题。”

在新会话里测试

应该触发

“ 我想看看最低工资上调对就业的影响。”
预期：调用 did-checklist ，先核对处理时间

不该触发

“ 帮我画一张收入的分布图。”
预期：不调用

- 没有调用：多半是 description 写得不对
- 调用了但跳过某一步：把那一步写得更明确

第 4 课要记住的三件事

计量、复现和 skill

1. 识别是人的判断。处理时间要有出处，看图标准事先写下。
2. 复现事先定容差，每个偏差都说清原因。
3. 反复做的流程写成 skill ， description 写触发条件，新会话测试。

讲义结束

现场演示与作业

演示按同样的三段走： DID 、复现、起草 skill 。然后讲课后作业。

现场演示（0:50–1:35）

- **DID**　可行性提问 → TWFE 和事件研究图 → 审稿子智能体指出处理时间问题
- 　　按实际起始时间重新编码，改用 csdid；结果不稳健，结论不能用
- **复现**　美貌经济学的复现目标表和对比报告
- **Skill**　起草 did-checklist，改 description，新会话测试

演示中的事件研究图为示意。

你会看到的



示意图

它给建议，采不采纳由你决定，理由写下来。

课后作业（约 2 小时）

DID 路线	复现路线
第 3 课的面板，自选一项政策 处理时间表（注明出处）→ 事件研究 写 did-checklist	一篇用同类数据的已发表论文 六项格式读论文 → 定容差 → 复现主表 写 replication-targets

- 没有 CHNS 或 CHARLS：用自己手头的数据，配一篇用同类数据的文献
- skill 要在新会话里测试：一句应该触发的话，一句不该触发的话
- 对照 **`lab4_verify_checklist.md`** 自查

Exit ticket 和下一课的准备

- **Exit ticket** 一个想明白的概念、一个出错的地方、下次相信结果前要核对什么
- **本课专属问题** 你的 skill 里，哪一条规则是从这次的错误里来的?
- **下一课** 理论建模、写作与可审计性；把第 3 或第 4 课的流程加固成复制包