朱晨的 AI 智能体课

Claude Code 经济学研究实战

第 6 课　研讨： AI 与经济学知识生产

朱晨　中国农业大学经济管理学院
公众号：遗传社科研究　GitHub： maxwell2732

遗传社科研究

今天的安排

- **0:00–0:40　讲座**　课后的学习； AI for Social Science 的验证问题；研究者的训练
- **0:40–1:10　案例**　Project APE 与 HLER
- **1:10–1:50　讨论**　三个问题，三到五人一组
- **1:50–2:00　总结**　课后的立场备忘录

本课没有实操作业。

前五课回顾

完成的任务

第 1 课 从模型到智能体	第 2 课 想法到图表	第 3 课 调查数据	第 4 课 计量与复现	第 5 课 理论、写作、交付
核对办法				
用独立来源 核对一个数字	合理性检查 留痕文件	哈希校验 合并报告	处理时间的出处 事先锁定容差	hook 全新克隆重跑

小结

每一课都留下了一种检查结果的办法。今天讨论的验证问题，可以看作这些办法的一般化。

第一部分

课后怎样继续学习

关于 skill 和工作流的一点个人经验。

一 课后的学习
二 AI for Social Science
三 研究者的训练
讨论与总结

关于 skill：少而熟

一次装很多

- 每个都试过，没有一个用熟
- 面对真实问题时难以选择
- 出错后难以定位原因

每周深入用一个

- 用在正在做的真实项目上
- 弄清楚它在什么情况下会出错
- 按自己的需要改一版，再换下一个

我的建议是每周只深入使用一个，用熟以后再换下一个。

一个可供参考的六周安排

	这一周深入使用	对应课次
第 1 周	CLAUDE.md 和 Plan mode	第 1 课
第 2 周	研究深度、广度、高度三套提示	第 2 课
第 3 周	research-harness 的审查和清理	第 3 课
第 4 周	自己写的 skill	第 4 课
第 5 周	hook 和全新克隆重跑	第 5 课
第 6 周	写作顺序：先写数据与方法，逐章写作	第 5 课

是否用熟：真实项目中用过三次以上；清楚它在哪些情况下会出错；按自己的需要改过一次。

第二部分

AI 能在多大程度上承担社会科学研究

从验证的角度看 AI for Science 与 AI for Social Science 的差别，并以 Project APE 和 HLER 为例。

一 课后的学习
二 AI for Social Science
三 研究者的训练
讨论与总结

研究结果由谁来验证

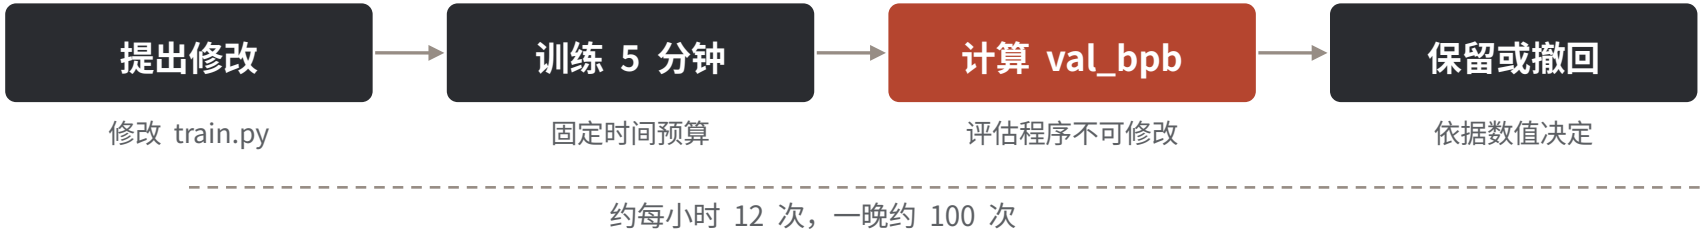
任务	标准答案	如何判定对错
计算器：2 + 2	4	明确、即时、几乎没有成本
根据经济数据判断政策是否有效	通常没有唯一答案	依赖研究设计、制度背景和领域知识

- 代码能运行，不能说明变量构造正确
- 系数显著，不能说明因果关系成立
- 行文流畅，不能说明引文真实、推理可靠

问题所在

生成研究结果的成本下降很快，验证结果的成本下降得慢得多。

AutoResearch 为什么能自动运行



- 智能体只需回答：在相同的数据、硬件和时间预算下，这次修改是否降低了 val_bpb
- 这是一个局部的评价标准。它能说明模型在设定条件下变好了，不能说明这是更广泛意义上的进展

来源： github.com/karpathy/autoresearch；朱晨（2026）， Why Is It Harder for AI to Become a Social Scientist?

AI for Science 与 AI for Social Science：反馈信号的差别

AI for Science （AI4S）

- 蛋白质结构可与实验观测比对
- 数学证明可由形式化验证器检查
- 模型改动可用验证集损失评估
- 反馈相对频繁、便宜、明确

AI for Social Science

- 概念和变量是否有效
- 识别假设是否可信
- 结论能否外推，政策含义是否成立
- 反馈稀少、多元，且常有争议

Oracle 密度

一个研究环境以多高的频率、多低的成本、多明确和可靠的方式，向智能体反馈结果的对错。

来源：朱晨（2026），Why Is It Harder for AI to Become a Social Scientist? 博文，7 月 25 日。

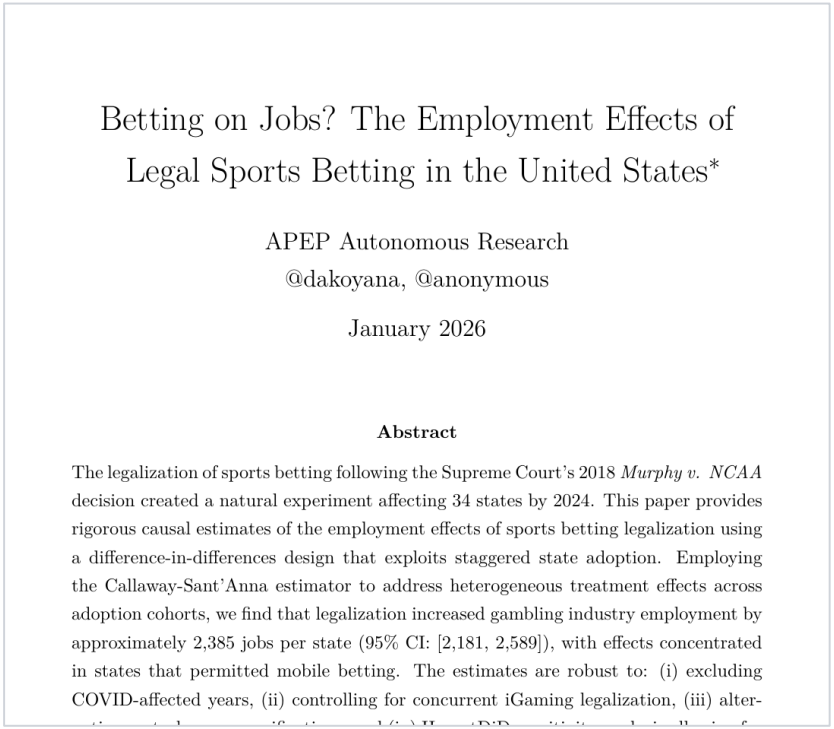
社会科学很难用单一指标衡量

如果唯一的目标是	智能体可能会
系数显著	反复更换变量、样本和模型设定
AI 审稿人的分数	写出更符合评审偏好的论证
预测精度	使用难以解释、甚至带有歧视的变量

论文的形式越来越完整，可信度并没有相应提高。

- 评价标准本身也有争议：贫困如何定义？教育质量看考试成绩还是长期能力？
- 因此需要多个局部的检验相互约束，单一指标不够

Project APE： 1,000 篇自动生成的政策评估论文



Betting on Jobs? The Employment Effects of Legal Sports Betting in the United States*

APEP Autonomous Research
@dakoyana, @anonymous

January 2026

Abstract

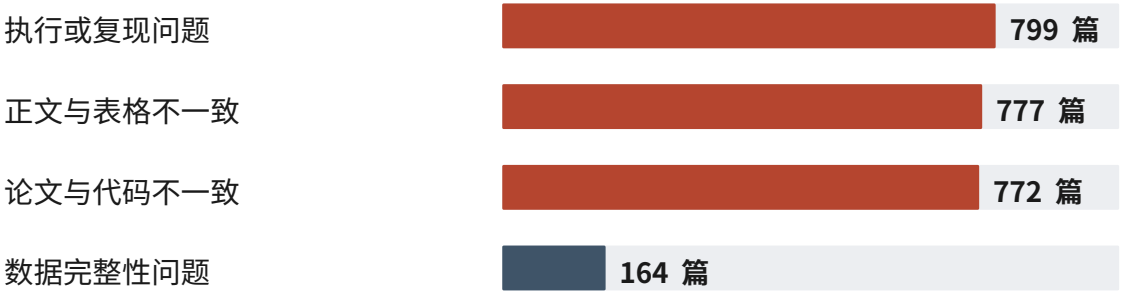
The legalization of sports betting following the Supreme Court's 2018 *Murphy v. NCAA* decision created a natural experiment affecting 34 states by 2024. This paper provides rigorous causal estimates of the employment effects of sports betting legalization using a difference-in-differences design that exploits staggered state adoption. Employing the Callaway-Sant'Anna estimator to address heterogeneous treatment effects across adoption cohorts, we find that legalization increased gambling industry employment by approximately 2,385 jobs per state (95% CI: [2,181, 2,589]), with effects concentrated in states that permitted mobile betting. The estimates are robust to: (i) excluding COVID-affected years, (ii) controlling for concurrent iGaming legalization, (iii) alter-

1,000	18,000+	88.1%
篇论文	场两两比较	人类论文胜出概率

- 2026 年 1–4 月生成，此后暂停生产，转入评估
- 选题、取数、估计、写作均由智能体完成
- LLM 评委与 AER 、 AEJ 论文两两比较
- 评委只读 PDF ，看不到代码和数据

来源： ape.socialcatalystlab.org ，截至 2026 年 10 月；左图为 apep_0038 第 2 版首页。

Project APE 的自我评估



各类问题涉及的论文数（共 1,000 篇，可重叠）

- 平均每篇 4.3 个问题； 84.2% 至少有一个严重问题
- 代码能运行 436 篇，其中 144 篇能复现文中表格

评审与核实不是一回事

论文可以读起来很有说服力，代码实现的却是另一套分析。只读 PDF 的评委发现不了这类问题。

来源： Project APE （2026）， Reliability of the first 1,000 papers， APE Briefs， 2026 年 10 月。

AI 论文的主要差距在选题

质量差距的构成



- 74% 的 AI 论文使用双重差分
- 912 篇中只有 7 篇在选题和执行上都超过人类论文中位数

AI 论文偏向文献密集区

- 越靠近文献密集区， AI 论文的表现越好
- 人类论文没有这个规律

对研究者的含义

学科交叉处、尚未充分利用的数据、求解成本很高的理论问题，是 AI 目前做得较差、更依赖研究者判断的地方。

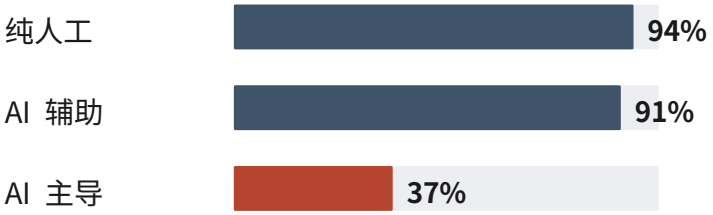
来源： Ning （2026）， The Ideation Bottleneck， arXiv:2604.03338； Zampa （2026）， Following the Crowd， VoxEU。

自动核查的进展与局限

APE： AI 核查器的测试

- 植入错误的检出率：最好的模型 99%
- 四个模型组合 99.3%，每篇约 0.07 美元
- 人工双人复核：每篇约 40 美元
- 核查器难以区分哪些发现是真错误

PNAS：复现实验



复现率；纯人工组发现的严重代码错误更多

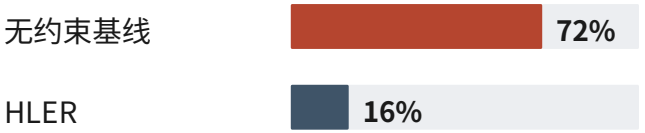
我的理解

核查中可以程序化的部分会越来越便宜。哪些问题实质性地影响结论、结论能推到多远，仍然需要研究者判断。

来源： Willner & Yanagizawa-Drott （2026）， Verifying the Verifiers； Brodeur et al. （2026）， PNAS， doi:10.1073/pnas.2524747123。

HLER：把可信度拆成可以核查的问题

- 引用的文献能否追溯到原文
- 数据处理是否由脚本完成，样本量变化是否有记录
- 识别依赖哪些假设，是否做了检验
- 结论是否超出了估计能支持的范围



严重失败率（280 次完整运行，四个数据集）

改善最大的是公开资料最少的数据：清代人口登记册

HLER 的设计

数据处理和估计由确定性的程序完成，语言模型只负责推理；关键决定由研究者在三个关口做出。

来源：Zhu, Wang & Zhang（2026），(Human) Attention Is (Still) All You Need，arXiv:2606.12848。

Oracle 工程

	AutoResearch	HLER 、 pAI-Econ
评价标准	单一标量： val_bpb	多个局部检验，相互约束
运行方式	可以整夜自动运行	较慢，关键环节需要研究者
适用的任务	目标可以计算的任务	评价标准本身有争议的研究

Oracle 工程

把一个难以直接评价的研究目标，拆成一组可以执行、可以核查、相互约束的反馈机制。

前五课用过的哈希校验、合并报告、事先锁定的容差、 hook 和全新克隆重跑，都属于这类局部检验。

第三部分

研究者的训练应该放在哪里

结合前面的证据，讨论判断力、学术品位与博士训练，以及如何看待关于 AI 的各种信息。

研究中需要判断的环节

选题

什么问题值得研究

识别

研究设计能否支撑因果解释

结论的边界

结论能推广到哪里，不能推广到哪里

取舍

结果不理想时，是否承认设计不成立

执行层面的差距在缩小，判断层面的差距仍然明显。

AI 能写论文以后，还需要读博吗

读博的意义从来不只是“写出一篇论文”。

它是一场针对学术品位（taste）与判断力（judgment）的系统训练：

什么样的现象值得做?	什么样的证据链才算闭环?	一个结论的边界在哪里?

我的看法

正是因为 AI 降低了文本生成的成本，人类对真实问题的辨别能力才变得真正不可替代。

如何看待关于 AI 的各种信息

常见的说法：“硅谷昨天发布了……，某某学科不存在了”

这类内容多以流量为目的，很少给出可以核查的依据。和读论文一样，可以按三步看：

找到原始来源 论文、代码或官方说明	看结果能否复现	判断与自己当前 研究的关系

新工具值得认真了解，但不必追逐每一条消息。即使不用 AI ，扎实的实证训练也依然有效。

研究者需要的两类能力

传统的科研能力

- 学科专业知识
- 理论理解与识别策略
- 批判性思维

与智能体协作的能力

- 把模糊的想法说清楚
- 把任务拆分给智能体
- 设计核对结果的办法
- 知道什么时候应该停下来自己判断

先后顺序

后一类以前一类为基础。刚入门的同学，应先通过传统训练建立知识框架。

第四部分

讨论与总结

三个讨论问题，以及课后的立场备忘录。

三个讨论问题

1

人力资本

数据清理和回归的成本下降以后，研究者的哪些人力资本会贬值，哪些会升值？哪些是通用的，哪些只在特定工具上有用？

2

来源与披露

一个发现由人还是由机器做出，是否重要？期刊的披露要求应该怎样定？

3

论文市场

一个项目四个月写出 1,000 篇论文。论文供给大幅增加以后，审稿和发表会怎样变化？

每组选一个问题：讨论 25 分钟，分享 2 分钟。

立场备忘录：2036 年我还靠什么做研究

- **写到具体环节**　选题、数据、识别、写作、审稿等，避免笼统的判断
- **有依据**　至少引用一篇阅读，并结合一次这六课中自己的经历
- **落到行动**　最后写一项接下来打算做的能力投资
- **论点是自己的**　可以请 AI 做编辑，说明用法

使用方式

不需要提交。建议两三位同学互相阅读，用研讨包里的互评表。只看论证是否具体，不看篇幅。

课程之后

逐个用熟

每周深入使用一个工具

完整走一遍

用自己的真实项目，从数据到复制包

公开可以公开的部分

代码、说明、可复现的例子

阅读

研讨包里的阅读清单

课程仓库： `github.com/maxwell2732/chenzhu-claude-econ`

阅读清单

- 朱晨（2026）. Why Is It Harder for AI to Become a Social Scientist? 博文，7 月 25 日
- Zhu, Wang & Zhang （2026）. (Human) Attention Is (Still) All You Need. arXiv:2606.12848
- Project APE （2026）. Reliability of the first 1,000 papers. APE Briefs，10 月
- Willner & Yanagizawa-Drott （2026）. Verifying the Verifiers
- Ning （2026）. The Ideation Bottleneck. arXiv:2604.03338
- Zampa （2026）. Following the Crowd. VoxEU
- Brodeur et al. （2026）. AI-assisted teams… PNAS
- Karpathy （2026）. autoresearch. GitHub

自动化能生成越来越密集的答案，
但经得起推敲的知识依然稀缺。

把计算和执行交给机器，
把辨别和取舍留给自己。

技术在变，但实证研究的门槛
和对因果关系的敬畏没有变。

路得一步步走。

谢谢大家 · 朱晨 · 公众号「遗传社科研究」